

Optimización de rutas de entrega (TSP, 15 ubicaciones)

Análisis comparativo de metaheurísticas · Recocido Simulado · Algoritmo Genético · Hill-Climbing

Rodrigo Mendoza Cortes
Artificial Intelligence Technologies Specialist

1. Análisis del problema

El reto es un **Problema del Agente Viajero (TSP)**: un repartidor debe visitar 15 ubicaciones de entrega exactamente una vez y regresar al origen, minimizando la distancia total. Es un problema **combinatorio**: el número de rutas posibles crece factorialmente (para 15 ciudades, $(15-1)!/2 = 43$ mil millones de rutas distintas). Evaluarlas todas por fuerza bruta es inviable, lo que justifica el uso de metaheurísticas: encuentran soluciones de calidad en tiempos razonables sin garantizar el óptimo absoluto.

Nota metodológica (dos precisiones del enunciado). (1) El enunciado ofrece "Hill-Climbing o Gradiente" en el Grupo 3, pero el descenso por gradiente es **inaplicable** a un TSP: no existe una función continua y diferenciable sobre permutaciones de ciudades, así que no hay gradiente que calcular. Por eso el Grupo 3 se resuelve con Hill-Climbing. (2) El enunciado menciona "vehículos de capacidad limitada", lo que describiría un CVRP (múltiples vehículos con restricción de carga); sin embargo, los 15 puntos y los pasos descritos corresponden a un TSP de ruta única, que es lo aquí implementado. Ambos puntos conviene confirmarlos con el instructor.

2. Técnicas implementadas

Se implementó una técnica de cada grupo, cubriendo las tres familias del curso:

Grupo	Técnica elegida	Familia
1	Recocido Simulado	Estado único (inspirado en física)
2	Algoritmo Genético	Poblacional (evolutivo)
3	Hill-Climbing (2-opt)	Estado único (búsqueda local)

2.1 Recocido Simulado — flujo general

```
ruta ← permutación aleatoria; T ← T_inicial
repetir hasta enfriar:
  vecino ← movimiento 2-opt aleatorio
  delta ← dist(vecino) - dist(ruta)
  si delta < 0 o random() < exp(-delta / T): aceptar vecino
  T ← T × factor_enfriamiento
devolver la mejor ruta vista
```

Clave: acepta empeoramientos con probabilidad $\exp(-\text{delta}/T)$. A temperatura alta explora mucho; al enfriarse se vuelve exigente. Así **escapa de óptimos locales**.

Detalles de implementación. Vecindad 2-opt (intercambio de dos aristas); enfriamiento geométrico $T \leftarrow T \times 0.95$ desde $T_{\text{inicial}}=10$ hasta $T_{\text{final}}=1e-3$, con 20 movimientos evaluados por nivel de temperatura. El delta de distancia se calcula de forma incremental (solo las 4 aristas afectadas), no recalculando la ruta completa en cada paso.

Fidelidad al material del curso. El criterio de aceptación de Metropolis ($\exp(-\Delta/T)$), el seguimiento de la mejor solución vista y el enfriamiento geométrico reproducen exactamente el algoritmo presentado en el curso. La única diferencia deliberada: el material evalúa un vecino y enfría en cada paso (una evaluación por nivel de temperatura), mientras que aquí se evalúan 20 vecinos por nivel antes de enfriar — la práctica estándar de la literatura de Recocido Simulado ("longitud de cadena de Markov por temperatura"), necesaria para que cada nivel de T tenga oportunidad real de explorar antes de bajar. No altera el algoritmo, solo su granularidad de enfriamiento.

2.2 Algoritmo Genético — flujo general

```
población ← rutas aleatorias
repetir por G generaciones:
    evaluar aptitud (1/distancia) de cada individuo
    conservar al mejor (elitismo)
    mientras no se llene la nueva población:
        padres ← selección por torneo
        hijo ← cruzamiento OX(padre1, padre2)
        con prob. p_mut: mutar(hijo) [inversión de segmento]
    devolver el mejor individuo
```

Usa los tres operadores del curso: **selección** (torneo), **cruzamiento** (Order Crossover, que garantiza permutaciones válidas) y **mutación** (inversión). La diversidad de la población le da robustez.

Detalles de implementación. Población de 40 individuos durante 100 generaciones; selección por torneo con $k=3$ competidores; mutación con probabilidad $p_mut=0.2$; elitismo de 1 individuo (el mejor pasa intacto a la siguiente generación, así nunca se pierde el mejor hallazgo). Cada individuo es un arreglo de numpy con una permutación de las 15 ciudades.

2.3 Hill-Climbing — flujo general

```
ruta ← permutación aleatoria
repetir:
    buscar el mejor movimiento 2-opt que reduzca la distancia
    si existe → aplicarlo
    si no existe → óptimo local alcanzado, terminar
```

Búsqueda local pura: solo se mueve a vecinos que mejoran. Es rapidísimo, pero se detiene en el primer óptimo local. Su variante **Random Restart** (reiniciar desde varias soluciones) es la mejora natural, y se propone en la sección 5.

Detalles de implementación. Se evaluó con un solo reinicio ($\text{reinicios}=1$) en el experimento principal, a propósito, para exponer su debilidad clásica: el atrapamiento en óptimos locales (ver sección 5.3 para la variante con reinicios). Cada iteración explora la vecindad 2-opt completa (todos los pares de aristas, $O(n^2)$) y aplica el mejor movimiento de mejora, no uno aleatorio.

3. Pruebas y resultados

Cada técnica se ejecutó **5 veces** con semillas distintas para observar variabilidad y convergencia. Se usó deliberadamente un **presupuesto computacional modesto**: con parámetros muy amplios las tres técnicas encuentran siempre el mismo óptimo (~ 32.22) y la varianza sería cero, lo que impediría comparar su comportamiento estocástico. La tabla reporta la mejor, promedio y peor distancia de las 5 corridas, más el tiempo promedio.

Técnica	Mejor	Promedio	Peor	Desv. std	Tiempo prom. (s)	Iter/Gen prom.
Recocido Simulado	32.22	33.04	34.04	0.782	0.134	3600
Algoritmo Genetico	32.22	32.35	32.87	0.260	0.616	100
Hill-Climbing	32.22	32.96	34.38	0.930	0.004	9

Tabla 1. Resultados sobre 5 corridas por técnica.

Lectura de los números. Las tres técnicas **alcanzan el óptimo** (≈ 32.22) en su mejor corrida, lo que confirma que 32.22 es la solución óptima (o muy cercana) para esta instancia. Las diferencias aparecen en la **consistencia** y el **costo**:

- **Algoritmo Genético** logra el mejor promedio (32.35) y la menor dispersión (std 0.260): la diversidad de la población lo hace el más **consistente**, a cambio de ser el más lento (0.616 s).
- **Recocido Simulado** queda intermedio en calidad (promedio 33.04) y muy rápido (0.134 s).
- **Hill-Climbing** es **el más rápido con enorme diferencia** (0.004 s), pero con la mayor variabilidad (std 0.930) y la peor peor-corrida (34.38): es el atrapamiento en óptimos locales en acción.

4. Visualización




Figura 1. Mejor ruta — Recocido Simulado.




Figura 2. Mejor ruta — Algoritmo Genético.




Figura 3. Mejor ruta — Hill-Climbing.

Las tres mejores rutas son geométricamente equivalentes (el mismo ciclo óptimo, sin cruces): la señal visual de una solución 2-opt convergida.




Figura 4. Convergencia comparada (mejor distancia vs. progreso normalizado de la búsqueda).

La curva de Recocido Simulado (naranja) muestra escalones y mesetas: acepta empeoramientos temporales antes de bajar. El Algoritmo Genético (azul) desciende por generaciones. Hill-Climbing (verde) cae de forma monótona y rápida hasta su óptimo local.

5. Análisis comparativo y mejoras

5.1 ¿Cuál obtuvo mejores resultados y por qué?

Depende del criterio. En **calidad promedio y consistencia**, gana el Algoritmo Genético: su población mantiene varias soluciones diversas simultáneamente, lo que reduce el riesgo de quedar atrapado en una mala región. En **eficiencia pura (tiempo)**, gana Hill-Climbing por dos órdenes de magnitud, aunque paga con inestabilidad. Un hallazgo relevante para esta instancia pequeña y bien comportada: las técnicas sofisticadas **no superan** en calidad al óptimo que también alcanza una búsqueda local simple; su ventaja real aparecería en instancias mayores o con paisajes de búsqueda más accidentados.

5.2 Ventajas y desventajas de cada enfoque

Técnica	Ventajas	Desventajas
Recocido Simulado	Escapa de óptimos locales; simple; rápido; un solo estado en memoria.	Muy sensible al esquema de enfriamiento; resultado variable si se enfría rápido.
Algoritmo Genético	Explora en paralelo; robusto y consistente; bueno en paisajes multimodales.	El más costoso; muchos parámetros (población, p_mut, torneo) que ajustar.
Hill-Climbing	El más rápido y simple; convergencia inmediata.	Se atasca en el primer óptimo local; alta varianza sin reinicios.

5.3 Propuesta de mejora por técnica

- **Recocido Simulado:** usar un enfriamiento adaptativo (reheating) que suba la temperatura si la búsqueda se estanca, y calibrar T_{inicial} con la aceptación inicial objetivo (~80%).
- **Algoritmo Genético:** hibridar con búsqueda local (memético): aplicar 2-opt a los mejores hijos cada cierto número de generaciones para acelerar la convergencia sin perder diversidad.
- **Hill-Climbing:** añadir **Random Restart** (varios reinicios) y/o escalada estocástica; con solo 4–5 reinicios esta instancia alcanza el óptimo de forma consistente, eliminando la varianza observada.

Mejora transversal: para instancias mayores o con capacidad de vehículos (CVRP), conviene una **hibridación** — por ejemplo, AG para exploración global seguido de 2-opt/recocido para refinamiento local — y precálculo de la matriz de distancias (ya aplicado) para no recalcular raíces cuadradas en cada evaluación.

6. Conclusiones

El problema de ruteo de 15 ubicaciones de entrega se resolvió con tres metaheurísticas, una por grupo del reto — Recocido Simulado (estado único, inspirado en física), Algoritmo Genético (poblacional) y Hill-Climbing (estado único, búsqueda local) — todas construidas sobre la misma vecindad 2-opt, lo que permite comparar su comportamiento en igualdad de condiciones.

Las tres técnicas alcanzan la misma distancia óptima (≈ 32.22) en su mejor corrida de las 5 ejecutadas, lo que valida las tres implementaciones de forma cruzada: si hubiera un error de lógica en alguna, no convergerían de forma independiente al mismo valor. La diferencia real entre ellas no está en la calidad máxima alcanzable, sino en la **consistencia** (qué tan seguido llegan cerca del óptimo) y el **costo computacional** por ejecutar la búsqueda.

En términos prácticos para una empresa de reparto: si el plan de rutas se calcula una vez al día y hay margen de tiempo, el **Algoritmo Genético** es la opción más confiable por su baja varianza. Si las rutas deben recalcularse en tiempo real (por ejemplo, ante un pedido de última hora), **Hill-Climbing con random restart** da resultados casi tan buenos en una fracción del tiempo. **Recocido Simulado** queda como una alternativa intermedia sólida cuando se prefiere un solo estado en memoria (sin mantener una población completa).

Para escalar esta solución al problema real descrito en el reto — vehículos de capacidad limitada (CVRP) e instancias con más de 15 puntos — el camino natural es la hibridación planteada en la sección 5.3: una técnica poblacional para explorar el espacio de soluciones globalmente, refinada con búsqueda local 2-opt/recocido para pulir cada ruta candidata.

Reporte generado con resultados reales de la ejecución de `run_experiments.py`. Los valores numéricos pueden variar ligeramente entre corridas por la naturaleza estocástica de los métodos; las conclusiones cualitativas se mantienen.